

Solana 潜在自动化交易地址识别与行为特征分析报告

项目名称：Solana 机器人活跃地址特征分析

分析时间段：2026年2月

报告日期：2026年3月8日

作者：雷宇辰

GitHub 仓库：https://github.com/Mi-Manchii/solana_bot_analyzer

1. 引言与背景

Solana 作为高性能区块链，承载了大量高频交易活动，其中自动化程序（如 MEV 机器人、做市商、套利机器人）占据重要地位。识别并分析这些自动化地址的行为特征，有助于理解链上生态结构、市场操纵风险以及网络资源使用情况。

本项目旨在从公开的候选地址列表中，筛选出在 2026 年 2 月内满足特定活跃度标准的地址，并对其交易行为进行多维度的量化特征分析。最终产出包括：筛选后的地址列表 (`addresses.csv`)、每个地址的行为特征 (`features.csv`)、以及反映特征分布的可视化图表。整个过程通过 Python 脚本实现一键运行，确保结果可复现。

2. 数据来源与筛选规则

2.1 候选地址来源

主要来源：我从GMGN上手动找到的一些机器人地址，评判标准主要有：七日交易量超过5000条；胜率高于75%或盈利率超过200%。

补充来源：GitHub 上的开源项目 "Solana-MEV-Bot-Blackbook"（由 outsmartchad 维护），该列表收集了社区报告的疑似 MEV 机器人地址，具有一定的可信度。我将其中符合条件的地址整合到了地址池文件 `address_pool.txt` 中。

2.2 活跃度筛选规则

为聚焦于高频、持续性自动化行为，我们设定了以下严格的筛选条件：

- 时间窗口限定：**为方便实现，我设定了两种模式：默认default是从当前日期向前回滚查找，直到2026年2月1日；feb模式是限定在 **2026年2月1日 00:00:00 UTC 至 2026年2月28日 23:59:59 UTC**。

2. **连续活跃天数**：地址在 2 月内必须存在至少一个 **连续7天** 的活跃窗口。这里“活跃”定义为该天至少有一笔交易。
3. **交易量门槛**：在该连续7天窗口内，**累计交易笔数必须 ≥ 1800 笔**。这一高阈值（平均每天约257笔）能够有效过滤掉普通用户的人工交易，锁定高频自动程序。
4. **数据完整性保证**：在扫描过程中，程序会**持续回溯获取签名，直到覆盖整个2月范围**（即获取到的最早交易时间戳 $\leq$ 2月1日 0:00）。确保不会因 `FETCH_LIMIT` 截断而遗漏早期交易，导致误判。

2.3 采集规则

- 对于每个候选地址，程序从其最新交易开始，以每页100条的方式获取签名历史，直到满足上述回溯要求或达到预设上限。
- 对于符合条件的地址，进一步获取2月内交易的详情（最多500笔，以平衡速度和特征准确性），用于提取程序ID和代币信息。

3. 特征工程

3.1 基础活跃度特征

特征名	计算方法	含义与解读
<code>avg_tx_per_day</code>	2月内日均交易数 $= \text{total_transactions} / \text{unique_days}$	衡量地址的日常交易强度。高值（如 >200 ）往往对应程序化高频交易。
<code>max_tx_in_day</code>	单日交易数的最大值	捕捉爆发性行为，例如机器人在特定事件（如新币上线）时瞬间发送大量交易。
<code>feb_2026_tx_count</code>	2月内交易总数	反映地址在分析期内的总体活动规模，高频机器人通常拥有极高的交易总量。

3.2 时间规律特征

特征名	计算方法	含义与解读
<code>night_ratio</code>	夜间（0:00-5:59 UTC）交易数 / 总交易数	夜间比例高（ >0.3 ）可能表明程序不受人工作息限制，全天候运行。
<code>weekend_ratio</code>	周末交易数 / 总交易数	周末比例若接近平日，则进一步支持自动化判断；若显著低于平日，可能涉及人工

特征名	计算方法	含义与解读
		干预。
<code>avg_interval_seconds</code>	相邻交易时间间隔的平均值（秒）	反映平均交易频率。间隔越短，频率越高。
<code>cv_interval</code>	间隔变异系数 = 标准差 / 平均值	无量纲，衡量交易节奏的规律性。 低CV（<1） 表示交易间隔均匀，可能对应固定频率的轮询； 高CV 表示交易突发性强，可能由事件驱动。
<code>hourly_entropy</code>	按小时（UTC）统计交易分布的香农熵	衡量全天活跃时段的分散程度。 高熵 （接近理论最大值4.58）说明全天交易均匀； 低熵 说明集中在少数小时，可能反映人工习惯。
<code>daily_cv</code>	每日交易数的变异系数	衡量日活跃度的波动性。高值表示某些天特别活跃，可能对应策略触发日。

3.3 交互多样性特征

特征名	计算方法	含义与解读
<code>unique_programs</code>	交互过的不同程序 ID 总数	衡量地址调用的智能合约种类数。专注于少数核心协议的机器人通常此值较低；跨协议套利机器人则可能较高。
<code>program_entropy</code>	按程序调用次数计算的香农熵	高熵 表示程序使用广泛且均衡，可能执行多样化策略； 低熵 表示高度集中在少数程序上。
<code>unique_tokens</code>	交互过的不同代币 Mint 地址总数	衡量交易的资产多样性。做市商或狙击机器人可能涉及大量代币。
<code>token_entropy</code>	按代币出现次数计算的香农熵	与 <code>program_entropy</code> 类似，针对代币。高熵表示代币交易分散，低熵表示集中在少数代币。

通过这组特征，我们可以区分专注于少数核心协议的专业机器人与广泛交互的套利程序。

4. 实现流程与技术细节

整个分析流程封装在 `main.py` 中，并通过 `src/` 目录下的模块化代码实现。主要流程如下：

4.1 地址获取阶段

- 优先读取本地 `address_pool.txt`（支持行内注释）。

- 若文件不存在，则从 `config.py` 中配置的 GitHub 源（默认为 MEV Bot Blackbook）获取候选地址。

4.2 并发扫描与窗口检测

- 使用 `ThreadPoolExecutor` 并发处理地址（默认并发数 2），以提高扫描效率。
- 对每个地址，从最新交易开始分页获取签名（`getSignaturesForAddress`），每页100条。
- 动态回溯停止机制：
 - 在 `feb` 模式下，若尚未找到符合条件的窗口，会持续回溯至 2 月 1 日之前，不受 `FETCH_LIMIT` 限制。
 - 每获取一页，立即对当前已获的 2 月内签名运行滑动窗口检测（窗口大小7天），若发现满足条件的窗口（交易数 ≥ 1800 ），则立即停止回溯，进入下一步详情获取。
- 在 `default` 模式下，则从最新交易回溯，寻找任意一个起始日期 ≥ 2 月1日的窗口，找到即停。

4.3 交易详情获取

- 对于符合条件的地址，取出 2 月内所有签名（或限制为最近的 `MAX_TX_FOR_DETAILS` 笔）。
- 采用串行方式获取每笔交易的详情（`getTransaction`），请求间隔由 `DETAILS_DELAY` 控制（默认 1 秒），以避免触发 RPC 429 限流。
- 从详情中解析出指令涉及的程序 ID 和转账涉及的代币 Mint，用于多样性特征计算。

4.4 特征计算与输出

- 调用 `feature_calculator.compute_features`，基于签名时间戳和交易详情生成所有特征。
- 将地址信息（来源、窗口起止、总交易数等）存入 `output/addresses.csv`。
- 将特征数据存入 `output/features.csv`。

4.5 可视化生成

- 主程序运行完毕后，自动调用 `generate_plots.py`，生成特征分布图（3张）和相关性热力图（1张），保存为 PNG 和 PDF 格式至 `output/` 目录。

5. 结果概览与分析

5.1 筛选结果统计

本次分析共处理候选地址 80 个，其中：


- 满足“连续7天窗口且交易数 ≥1800”的地址：56 个（目标≥50）。
- 筛选通过率：70 %。

	A	B	C	D	E	F	G	H	I	J	K
1	address	source_label	source_label	first_seen	last_seen	active_days	tx_count_7	window_start	window_end	total_tx_available	
2	2PLVmdkQ9fC	Custom Address Pool		2026/2/25	2026/3/3	7	28000	2026/2/25	2026/3/3	28000	
3	MWRZZ7WwPo	Custom Address Pool		2026/2/26	2026/3/8	7	5730	2026/2/26	2026/3/4	6000	
4	2hLexBUxTeI	Custom Address Pool		2026/3/2	2026/3/8	7	3900	2026/3/2	2026/3/8	3900	
5	6K8WfpZuK2H	Custom Address Pool		2026/3/2	2026/3/8	7	35200	2026/3/2	2026/3/8	35200	
6	14ihgruds5c	Custom Address Pool		2026/3/2	2026/3/8	7	22200	2026/3/2	2026/3/8	22200	
7	chepnltuJFf	Custom Address Pool		2026/3/2	2026/3/8	7	20200	2026/3/2	2026/3/8	20200	
8	34amrAxWA6\	Custom Address Pool		2026/3/2	2026/3/8	7	17900	2026/3/2	2026/3/8	17900	
9	14dmUdeMazr	Custom Address Pool		2026/3/2	2026/3/8	7	13100	2026/3/2	2026/3/8	13100	
10	GG6CnDBfBgI	Custom Address Pool		2026/3/2	2026/3/8	7	9700	2026/3/2	2026/3/8	9700	
11	9yzDcVC569i	Custom Address Pool		2026/3/2	2026/3/8	7	12800	2026/3/2	2026/3/8	12800	
12	...	...	...	...	...	...	...	...	...	...	...

表 1：前 10 个符合条件的地址及其基础信息


5.2 特征分布分析

- 日均交易数分布




日均交易数分布呈左偏，多数地址集中在 1000~3000 笔/天，表明筛选出的机器人普遍保持极高交易频率，符合自动化程序的高强度运行特征。少数地址日均超过 5000 笔，可能为超高频做市商或套利机器人，交易密度更大。

- 小时交易熵分布




小时交易熵衡量地址在一天24小时内交易分布的均匀程度，理论最大值为4.58（完全均匀）。从数据看，熵值分布在 3.6至4.65 之间，覆盖了从相对集中到接近均匀的宽范围，表明机器人行为存在显著分化：高熵值（>4.5）的地址全天各小时交易量均衡，可能为7×24小时不间断运行的自动化程序；低熵值（<3.8）的地址交易集中在特定时段，可能与人工操作习惯或特定市场事件相关。

- 平均交易间隔分布




该特征统计了地址相邻交易时间间隔的平均值，直接反映交易频率。分布呈现**左偏**，多数地址的平均间隔集中在 **50秒以内**，表明这些地址以极高频率运行（日均交易量可达数千笔），符合高频机器人的典型特征。少数地址平均间隔超过200秒，交易频率相对较低，可能对应策略周期较长或仅在特定时段活跃的机器人。整体而言，分布印证了筛选出的地址普遍具有高频交易属性，且内部存在频率分层。

- **程序调用种类数分布**




大多数地址调用程序种类集中在5种，表明这些机器人主要与少数核心DeFi协议（如Jupiter、Raydium）交互，执行特定策略如套利或狙击，呈现高度专业化。少数地址达到7-9种，可能执行跨协议做市或多策略交易，体现策略多样性。整体分布左偏，符合自动化程序追求高效、聚焦核心合约的行为模式。

- **程序调用熵 (`program_entropy`) 分布**



大部分地址的程序熵值在2.3左右，说明它们主要与少数几种核心程序（如Jupiter、Raydium、Orca）交互，具有专业化特征。少数熵值较高的地址可能执行复杂的跨协议套利。


• 代币种类数分布



这一形态表明：多数机器人主要围绕少数热门Meme币进行高频交易，策略聚焦、目标明确；而少数地址涉及大量代币，可能扮演做市商或多品种套利者角色，需要在更广泛的资产池中操作。整体符合自动化程序追求效率与专注的核心特征。

然而也有可能因为地址交易太过频繁且我选取的特征分析交易数太少，导致分析较片面。


- **代币交互熵 分布**



代币交互熵衡量地址交易代币的分散程度。分布呈左偏，多数地址熵值集中在较低区间，表明其交易高度集中于少数几种代币（如主流稳定币或热门 Meme 币），策略聚焦、效率优先。少数地址熵值较高，代币交易分散，可能承担做市或多品种套利角色。整体符合机器人追求专注、规避复杂性的一般规律。

5.3 相关性分析

特征相关性矩阵



- **活跃天数与间隔标准差** ($r=0.81$) 强正相关，即活跃天数越多的地址，其交易间隔波动越大。这可能是因为长时间活跃的地址会经历不同市场环境，导致交易节奏变化（如平静期与爆发期交替）。
- **小时熵与每日交易CV** ($r=-0.68$) 负相关，即小时分布越均匀（熵高），每日交易量的波动性反而越小。这可能意味着全天均匀活跃的地址具有更稳定的日交易量，属于“平稳型”机器人；而小时集中活跃的地址则日间波动更大。

6. 局限性与未来工作

6.1 当前局限性

1. **数据源偏差**：候选地址可能无法覆盖所有类型的高频程序，这可能导致分析结论存在选择性偏差。

2. **交易详情采样**：为平衡 RPC 压力与计算效率，程序/代币多样性特征基于最多 500 笔交易计算。若地址 2 月内交易量极大，采样可能遗漏低频交互的程序或代币。
3. **无标签验证**：筛选出的地址虽然满足高频条件，但无法 100% 确认为自动化程序。

6.2 未来可拓展方向

- **多源标签融合**：集成 Dune Analytics、Solscan 标签或通过程序交互模式来增强地址的自动化判别能力。
- **行为聚类分析**：基于计算出的特征，使用无监督学习对地址进行聚类，发现不同的“机器人类型”（如套利型、狙击型、做市型）。
- **长期跟踪**：扩展时间范围至多个月份，分析地址行为的稳定性与季节性变化。

7. 可复现性说明

本项目提供完整的代码和文档，确保结果可复现：

- **运行环境**：Python 3.9+，依赖库见 `requirements.txt`。
- **一键执行**：项目根目录下提供 `run.sh`（Linux/macOS）或直接运行 `python main.py`，程序会自动完成地址获取、筛选、特征计算和图表生成。
- **配置文件**：所有可调参数（如并发数、RPC 端点、目标地址数量、模式选择）均集中在 `src/config.py` 中，便于用户自定义。
- **输出目录**：所有结果（CSV 和图表）统一保存在 `output/` 文件夹，便于查阅和分享。

附录 A：配置参数示例

```
# config.py 关键参数
MIN_CONTINUOUS_DAYS = 7
MIN_TX_IN_WINDOW = 1800
FETCH_LIMIT = 50000
TARGET_ADDRESS_COUNT = 100
MODE = 'default'

# 窗口长度
# 窗口交易量阈值
# 单地址最多获取签名数
# 目标收集地址数
# 'feb' 或 'default'
```